

Classification de sentiments par réseau de neurones récurrent tensoriel

Thomas Moreau
Ecole polytechnique
thomas.moreau@polytechnique.edu

Bertrand Rondepierre
Ecole polytechnique
bertrand.ronddepierre@polytechnique.edu

Résumé—Dans ce travail on étudie un modèle de réseau de neurones récurrent tensoriel utilisé pour faire de la prédiction de sentiments.

I. ENTRAÎNEMENT DU MODÈLE

A. Critère d'entraînement

En notant $\theta = (W, W_s, V, L)$ les paramètres du modèle on définit l'énergie suivante à partir de la distance de Kullback-Leibler (le signe moins est bien présent contrairement à la formule donnée dans l'article) :

$$E(\theta) = - \sum_{i \in \text{Noeuds}} \sum_{j=1}^C t_j^i \log y_j^i + \lambda \|\theta\|^2$$

Pour simplifier les notations, on réservera l'index i aux noeuds du réseau.

B. Equations de backpropagation

On notera en préliminaire avec le softmax :

$$\sigma_j(y) = \frac{e^{y_j}}{\sum_k e^{y_k}}$$

que la dérivée est simplement :

$$\partial_i \sigma_j(y) = (\delta_{i,j} - \sigma_i(y)) \sigma_j(y)$$

1) *Gradient par rapport à W_s* : On fait donc le calcul de la dérivée par rapport à $[W_s]_{kl}$ qui est différent des suivants puisqu'il ne s'agit pas encore de rétropropagation $y_j^i = \sigma_j(W_s x^i)$:

$$\begin{aligned} \frac{\partial E}{\partial [W_s]_{kl}} &= - \sum_i \sum_j \frac{t_j^i}{y_j^i} \frac{\partial y_j^i}{\partial [W_s]_{kl}} \\ &= - \sum_i \sum_j \sum_{c=1}^C t_j^i \delta_{kc} (\delta_{cj} - \sigma_c(W_s x^i)) x_l^i \\ &= - \sum_i \sum_j t_j^i (\delta_{kj} - y_k^i) x_l^i \\ &= \sum_i (y_k^i - t_k^i) x_l^i \end{aligned}$$

Donc chaque nœud i contribue au gradient par un terme $(y^i - t^i)(x^i)^T$.

2) *Gradients par rapport aux autres θ* : Pour comprendre le terme de rétropropagation, on va dériver par rapports aux paramètres autres que W_s :

$$\begin{aligned} \frac{\partial E}{\partial \theta} &= - \sum_i \sum_j \frac{t_j^i}{y_j^i} \frac{\partial y_j^i}{\partial \theta} \\ &= - \sum_i \sum_j \sum_c t_j^i (\delta_{pj} - y_p^i) \left[W_s \frac{\partial x^i}{\partial \theta} \right]_c \\ &= \sum_i \sum_j (y_j^i - t_j^i) \left[W_s \frac{\partial x^i}{\partial \theta} \right]_j \\ &= \sum_i (y^i - t^i) W_s \frac{\partial x^i}{\partial \theta} \end{aligned}$$

Pour le nœud i on note i_g et i_d les indices des fils gauche et droite. On a donc :

$$x_j^i = f \left(\begin{bmatrix} x_{i_g}^i \\ x_{i_d}^i \end{bmatrix}^T V^{[j]} \begin{bmatrix} x_{i_g}^i \\ x_{i_d}^i \end{bmatrix} + W_{j:} \begin{bmatrix} x_{i_g}^i \\ x_{i_d}^i \end{bmatrix} \right)$$

On voit donc que $\partial x^i / \partial \theta$ va comporter deux parties : une partie qui constitue le gradient en propre pour le nœud i , et une partie en facteur de $\frac{\partial}{\partial \theta} \begin{bmatrix} x_{i_g}^i \\ x_{i_d}^i \end{bmatrix}$ qui va se rétropropager aux fils $x_{i_g}^i$ et $x_{i_d}^i$. On note $\delta^{i,s} = W_s^T (y^i - t^i)$. On a alors en considérant que la fonction d'activation a une dérivée simple en fonction d'elle même comme c'est le cas pour tanh $f'(x) = F(f(x))$

$$\begin{aligned} \frac{\partial x_j^i}{\partial \theta} &= F(x_j^i) \left(2 \begin{bmatrix} x_{i_g}^i \\ x_{i_d}^i \end{bmatrix}^T V^{[j]} + W_{j:} \right) \frac{\partial}{\partial \theta} \begin{bmatrix} x_{i_g}^i \\ x_{i_d}^i \end{bmatrix} \\ &\quad + \begin{bmatrix} x_{i_g}^i \\ x_{i_d}^i \end{bmatrix}^T \frac{\partial V^{[j]}}{\partial \theta} \begin{bmatrix} x_{i_g}^i \\ x_{i_d}^i \end{bmatrix} + \frac{\partial W_{j:}}{\partial \theta} \begin{bmatrix} x_{i_g}^i \\ x_{i_d}^i \end{bmatrix} \end{aligned}$$

On voit apparaître en première ligne la partie qui se rétropropage aux fils et en deuxième ligne la partie propre au nœud i . Ainsi le gradient total va s'écrire :

$$\frac{\partial E}{\partial \theta} = \sum_i (\delta^{i,comp})^T \mathcal{E}^{i,\theta}$$

En notant $\mathcal{E}_j^{i,\theta}$ la partie propre au nœud i , et $\delta_{j:}^{i,prop}$ la partie rétropropagée, soit :

$$\mathcal{E}_j^{i,\theta} = \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix}^T \frac{\partial V^{[j]}}{\partial \theta} \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix} + \frac{\partial W_{j:}}{\partial \theta} \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix}$$

$$\delta_{j:}^{i,prop} = F(x_j^i) \left(2 \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix}^T V^{[j]} + W_{j:} \right)$$

Cette dernière partie rétropropagée se somme sur les j pour donner un total :

$$\delta^{i,down} = \sum_j \delta_j^{i,s} \delta_{j:}^{i,prop}$$

$$= \sum_j 2(\delta_j^{i,s} F(x_j^i)) V^{[j]} \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix} + W^T (\delta^{i,s} \otimes F(x^i))$$

Et on a donc les updates suivants pour calculer les $\delta^{i,comp}$ en notant p_i le père du noeud i qui qualifie l'algorithme de rétropropagation :

$$\delta^{i,comp} = \delta^{i,s} + \delta^{p_i,down}[1 : d] \text{ Si } i \text{ est le fils gauche}$$

$$= \delta^{i,s} + \delta^{p_i,down}[d + 1 : 2d] \text{ Si } i \text{ est le fils droit}$$

Reste donc à calculer les différentes parties propres pour chaque paramètre.

3) *Par rapport au biais W* : La partie propre de la dérivée par rapport à W_{kl} s'écrit :

$$\frac{\partial W_{j:}}{\partial W_{kl}} \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix} = \delta_{kj} \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix}_l$$

D'où la partie propre (contribution des noeuds pères uniquement) :

$$\delta_k^{i,comp} \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix}_l$$

Soit pour le noeud i une contribution :

$$\frac{\partial E^i}{\partial W} = \delta^{i,comp} \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix}^T$$

4) *Par rapport au tenseur V* : De même la partie propre pour le paramètre $V_{kl}^{[j]}$:

$$\frac{\partial E^i}{\partial V_{kl}^{[j]}} = \delta_j^{i,comp} \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix}_k \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix}_l$$

Soit un total :

$$\frac{\partial E^i}{\partial V^{[j]}} = \delta_j^{i,comp} \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix} \begin{bmatrix} x^{i_g} \\ x^{i_d} \end{bmatrix}^T$$

5) *Par rapport au dictionnaire L* : Enfin pour les coefficients de L , seuls les feuilles font une contribution lorsque $x^i = L_k$, qui se lit directement :

$$\frac{\partial E^i}{\partial L_k} = \delta^{i,comp} \delta(x^i = L_k)$$